

# 蒙特卡洛方法 (Monte Carlo Method)

杨其臻

Sep 19, 2025

蒙特卡洛方法是一种基于随机抽样的数值计算技术，用于解决复杂积分、概率模拟和优化等问题。本文将从理论入手，讲解其核心原理，并通过 Python 实现几个经典案例，帮助读者从实践角度深入理解这一方法。

蒙特卡洛方法得名于摩纳哥的蒙特卡洛赌场，源于 20 世纪 40 年代曼哈顿计划中冯·诺依曼和乌拉姆等人的工作。其核心思想是利用随机性来解决确定性问题，例如，通过投掷飞镖来估算圆周率  $\pi$ ：在一个单位圆的外接正方形内随机投点，统计落在圆内的点的比例，从而近似  $\pi$  的值。这种方法直观易懂，因为它是基于「用频率逼近概率，用样本均值逼近理论积分」的基本统计原理。蒙特卡洛方法的主要优点包括实现简单、不受问题维度限制，能够有效克服「维度灾难」；但其缺点在于计算精度依赖于采样数量，收敛速度较慢，为  $O(1/\sqrt{N})$ ，这意味着需要大量样本才能获得高精度结果。本文将逐步引导读者从理论基础到实际编码，全面掌握蒙特卡洛方法的应用。

## 1 蒙特卡洛方法的理论基石

蒙特卡洛方法的有效性建立在两大统计定律之上：大数定律和中心极限定理。大数定律指出，当试验次数足够多时，样本的平均值将无限接近理论的期望值，这为蒙特卡洛方法的收敛性提供了根本保证。例如，如果我们通过随机采样来估计一个积分，样本均值会随着采样数量的增加而趋近于真实值。中心极限定理则说明，大量独立随机变量的和近似服从正态分布，这使得我们能够估计蒙特卡洛方法的误差和置信区间；具体来说，误差正比于  $1/\sqrt{N}$ ，其中  $N$  是样本数量。从数学角度，蒙特卡洛方法将积分问题转化为期望计算：假设我们需要计算积分  $I = \int_a^b f(x)dx$ ，这可以视为随机变量  $f(X)$  的期望  $E[f(X)]$ ，其中  $X$  在区间  $[a, b]$  上均匀分布。通过生成大量随机样本  $X_i$ ，我们可以用样本均值来近似积分： $I \approx (b - a) \cdot \frac{1}{N} \sum_{i=1}^N f(X_i)$ 。这种转换使得复杂积分变得可计算，只需通过随机采样即可。

## 2 动手实战 - Python 实现经典案例

在开始编码前，我们需要导入必要的 Python 库，包括 numpy 用于数值计算和随机数生成，以及 matplotlib 用于可视化。我们将通过三个案例来演示蒙特卡洛方法的实际应用。

### 2.1 案例一：计算圆周率 $\pi$

计算圆周率  $\pi$  是蒙特卡洛方法的经典示例。问题基于几何原理：单位圆的面积是  $\pi$ ，而外接正方形的面积是 4，因此圆的面积与正方形面积之比为  $\pi/4$ 。算法思路是在正方形区域内随机生成点，并统计落在圆内的点的数量，从而估算  $\pi$  值。具体地，我们生成在  $[-1, 1] \times [-1, 1]$  范围内的随机点  $(x, y)$ ，计算每个点到原点的距离

$\sqrt{x^2 + y^2}$ , 如果距离小于或等于 1, 则点落在圆内。最终,  $\pi$  的估计值为 4 乘以圆内点数与总点数的比值。

以下是 Python 代码实现。首先, 我们导入库并设置参数, 如样本数量  $N$ 。然后, 使用 numpy 的 random.uniform 函数生成均匀分布的随机点。接着, 通过向量化操作计算每个点的距离, 并统计圆内的点数。最后, 计算  $\pi$  的估计值并输出结果。

```
1 import numpy as np
  import matplotlib.pyplot as plt
3
  N = 100000 # 样本数量
5 x = np.random.uniform(-1, 1, N)
  y = np.random.uniform(-1, 1, N)
7 distance = np.sqrt(x**2 + y**2)
  inside_circle = distance <= 1
9 pi_estimate = 4 * np.sum(inside_circle) / N
  print(f"估计的π值: {pi_estimate}")
```

代码解读: 这段代码首先生成  $N$  个在  $[-1, 1]$  区间内的随机点  $x$  和  $y$ , 然后计算每个点到原点的欧几里得距离。条件判断 `inside_circle` 是一个布尔数组, 表示点是否在圆内。求和操作 `np.sum(inside_circle)` 统计圆内点的数量, 最终乘以 4 得到  $\pi$  的估计。由于随机性, 每次运行结果会略有不同, 但随着  $N$  增大, 估计值会趋近于真实  $\pi$ 。为了分析收敛性, 我们可以计算误差并绘制图表, 例如误差随  $N$  变化的曲线, 验证  $O(1/\sqrt{N})$  的收敛速度。

## 2.2 案例二: 计算定积分

蒙特卡洛方法可用于计算复杂定积分, 例如积分  $I = \int_0^2 (\sin(x) + \cos(x^2)) dx$ 。算法思路是在积分区间  $[0, 2]$  上均匀采样, 生成随机点  $x_i$ , 然后计算函数值的平均值, 并乘以区间长度  $(2 - 0) = 2$  来估计积分值。这种方法简单直接, 但精度依赖于采样数量。

Python 代码实现如下。我们定义被积函数  $f(x)$ , 然后生成均匀分布的随机样本, 计算函数值的均值, 并乘以区间长度得到积分估计。

```
def f(x):
2     return np.sin(x) + np.cos(x**2)
4
  a = 0
  b = 2
6 N = 100000
  x_samples = np.random.uniform(a, b, N)
8 f_values = f(x_samples)
  integral_estimate = (b - a) * np.mean(f_values)
10 print(f"积分估计值: {integral_estimate}")
```

代码解读: 这里, `np.random.uniform(a, b, N)` 生成在  $[a, b]$  区间内的  $N$  个随机点。函数  $f(x)$  applied 到这

些点上，得到 `f_values` 数组。`np.mean(f_values)` 计算样本均值，然后乘以区间长度  $(b - a)$  来近似积分。与 `scipy.integrate.quad` 等数值积分方法对比，蒙特卡洛方法在低维问题中可能效率较低，但它的优势在于高维积分，其中传统方法会遇到困难。进阶地，我们可以讨论重要性采样来优化方差，例如通过调整采样分布来聚焦于函数值较大的区域，从而提高效率。

### 2.3 案例三：赌博游戏模拟 - 赌徒的破产

赌徒的破产问题是一个概率模拟示例，演示蒙特卡洛方法在随机过程中的应用。问题描述：一个赌徒有初始本金，每次赌博以概率  $p$  赢 1 元，概率  $q = 1 - p$  输 1 元，目标是模拟他最终破产（本金为 0）或达到目标金额的过程。算法思路是通过多次独立实验（即模拟多个赌徒的赌博过程），统计破产的次数，从而估计破产概率。每次实验模拟一个赌徒的序列直到破产或成功。

Python 代码实现中，我们定义一个函数来模拟单个赌徒的命运，然后循环多次实验来统计破产概率。

```
def simulate_gambler(initial_capital, target, p):  
2     capital = initial_capital  
    while capital > 0 and capital < target:  
4         if np.random.rand() < p:  
            capital += 1  
6         else:  
            capital -= 1  
8     return capital == 0 # 返回是否破产  
  
10 initial_capital = 10  
    target = 20  
12 p = 0.5  
    num_experiments = 10000  
14 bankrupt_count = 0  
    for _ in range(num_experiments):  
16         if simulate_gambler(initial_capital, target, p):  
            bankrupt_count += 1  
18 bankrupt_probability = bankrupt_count / num_experiments  
    print(f"破产概率: {bankrupt_probability}")
```

代码解读：`simulate_gambler` 函数使用 `while` 循环来模拟赌博过程，直到本金为 0（破产）或达到目标金额。`np.random.rand()` 生成  $[0,1)$  之间的随机数，用于模拟赢的概率  $p$ 。主循环中，我们进行 `num_experiments` 次实验，统计破产次数，并计算破产概率。这种方法通过大量随机实验来逼近理论概率，体现了蒙特卡洛模拟的核心。可视化方面，我们可以绘制破产概率随初始本金或  $p$  变化的曲线，例如使用 `matplotlib` 的 `plot` 函数来展示趋势。

### 3 蒙特卡洛方法的优化与扩展方向

尽管基础蒙特卡洛方法简单有效，但其收敛速度较慢，因此优化方差缩减技术至关重要。重要性采样是一种常见优化，通过调整采样分布来更频繁地对重要区域采样，从而减少方差。对偶变量法利用随机数的对称性来抵消方差，例如在积分计算中使用配对样本。控制变量法则用一个已知期望的变量来修正估计量，提高精度。这些技术都能显著降低计算成本，使蒙特卡洛方法更高效。扩展应用领域包括强化学习中的蒙特卡洛控制、金融工程中的期权定价、计算机图形学中的路径追踪渲染，以及物理学中的粒子模拟。这些高级应用展示了蒙特卡洛方法的广泛适用性和强大能力。

本文回顾了蒙特卡洛方法的核心原理，包括大数定律和中心极限定理的理论基础，并通过 Python 实战演示了其在圆周率计算、积分估算和概率模拟中的应用。蒙特卡洛方法的优势在于其通用性和简单性，但局限性在于收敛速度慢和有时需要大量计算。未来，读者可以探索更先进的方差缩减技术或应用于特定领域如机器学习。鼓励读者在实践中尝试这一方法，因为它就像一把「瑞士军刀」，能灵活解决各种复杂问题。深入学习方向包括马尔可夫链蒙特卡洛（MCMC）等高级主题。